

Други пројекат - FAQ

ШТА ТАЧНО ПРЕДСТАВЉА ПРИЛОЖЕНИ СКУП ПОДАТАКА?

Уз задатак ће бити приложени фајлови *users.txt*, *connections.txt* и *blocked.txt*. Обавезно је користити приложени скуп података. Студенти не треба сами да преузимају *SNAP dataset*, нити да сами праве синтетички скуп података. Скуп података је припремљен тако да омогући тестирање *PageRank*-а, претраге, *autocomplete*-а, *BFS* обиласка и хибридних препорука.

КОЈИ СКУП ПОДАТАКА ТРЕБА КОРИСТИТИ ТОКОМ РАЗВОЈА И ОДБРАНЕ?

Small се препоручује за развој и брзо тестирање, *medium* за демонстрацију интерактивног рада, а *full* за проверу перформанси над већим бројем података. Апликација треба да ради над све три величине.

ШТА ПРЕДСТАВЉА ФАЈЛ *USERS.TXT*?

Фајл *users.txt* садржи податке о корисницима у формату:

id|username|bio

id је јединствени идентификатор корисника, *username* је корисничко име, а *bio* је текстуални опис профила корисника. Биографија се користи за претрагу по кључним речима и за рачунање сличности корисника у хибридним препорукама.

ШТА ПРЕДСТАВЉА ФАЈЛ *CONNECTIONS.TXT*?

Фајл *connections.txt* садржи усмерене везе праћења у формату:

from_id|to_id

То значи да корисник *from_id* прати корисника *to_id*. Граф је усмерен, тако да веза *from_id|to_id* не значи да и корисник *to_id* прати корисника *from_id*.

ШТА ПРЕДСТАВЉА ФАЈЛ *BLOCKED.TXT*?

Фајл *blocked.txt* садржи податке о блокирању у формату:

blocker_id|blocked_id

blocker_id је корисник који је блокирао другог корисника, а *blocked_id* је корисник који је блокиран. Блокирање није глобално својство корисника, већ однос између два корисника.

ДА ЛИ БЛОКИРАНЕ КОРИСНИКЕ ТРЕБА ПОТПУНО ИЗБАЦИТИ ИЗ ГРАФА?

Не. Блокиране кориснике не треба брисати из графа. Блокирање треба узети у обзир приликом препорука, додавања нових веза, и претраге (ако је имплементирана из

перспективе конкретног корисника). На пример, ако је корисник А блокирао корисника В, онда корисника В не треба препоручивати кориснику А. Такође, ако је блокирање између два корисника присутно у било ком смеру, не треба дозволити додавање нове follow везе између њих.

ШТА ТАЧНО ПРЕДСТАВЉА ЗАДАТАК 2 - PAGERANK АЛГОРИТАМ?

Задатак 2 подразумева да се над графом праћења израчуна утицај сваког корисника. Корисник је утицајнији ако ка њему води више важних веза, односно ако га прате корисници који су и сами важни у мрежи. Потребно је имплементирати итеративни *PageRank* алгоритам, а не само пребројати колико пратилаца корисник има.

ДА ЛИ ЈЕ ДОВОЉНО РАНГИРАТИ КОРИСНИКЕ САМО ПО БРОЈУ ПРАТИЛАЦА?

Не. Број пратилаца може бити користан као додатна информација, али није замена за *PageRank*. *PageRank* узима у обзир и значај корисника који праве везе, па две везе не морају имати исту тежину у смислу утицаја.

ДА ЛИ СЕ PAGERANK РАЧУНА САМО ЈЕДНОМ ПРИЛИКОМ ПОКРЕТАЊА ПРОГРАМА?

PageRank се иницијално рачуна након учитавања графа. Након додавања новог корисника или нове везе праћења, потребно је поново израчунати *PageRank*. Дозвољено је користити претходно израчунате вредности као почетну тачку за ново рачунање, односно применити *warm start*.

ДА ЛИ ЈЕ ДОЗВОЉЕНО КОРИСТИТИ УНАПРЕД ИЗРАЧУНАТ PAGERANK.TXT?

Дозвољено је користити кеширане *PageRank* вредности ако су приложене, али програм треба да уме да израчуна *PageRank* над графом и да га поново израчуна након додавања новог корисника или *follow* везе.

ШТА ЗНАЧИ ПРЕТРАГА ПО КЉУЧНИМ РЕЧИМА ИЗ БИОГРАФИЈЕ?

Биографија је обичан текстуални опис профила. Претрага по кључним речима значи да се тај текст обради и подели на речи. На пример, ако нечија биографија садржи текст “*Machine learning* researcher and *Python* developer”, онда би тај корисник требало да се може пронаћи упитима као што су *machine*, *learning*, *researcher* или *python*. Не очекује се да постоји посебна листа ручно означених кључних речи.

ДА ЛИ ПРЕТРАГА ПО БИОГРАФИЈИ ТРЕБА ДА РАДИ КАО ПРЕТРАГА ЦЕЛОГ ТЕКСТА ИЛИ САМО КАО ПРОВЕРА ДА ЛИ ЈЕ УНЕТА РЕЧ ДОСЛОВНО САДРЖАНА У БИОГРАФИЈИ?

Основна идеја је да се ради *text processing* над биографијом и да се формира *inverted index*. То значи да се за сваку реч памти у којим се биографијама појављује. Када корисник унесе упит, систем проналази кориснике чије биографије садрже речи из тог упита. Дозвољено је имплементирати и напреднију варијанту, али није неопходно.

ДА ЛИ ПРЕТРАГА ТРЕБА ДА БУДЕ ОСЕТЉИВА НА ВЕЛИКА И МАЛА СЛОВА?

Не. Претрага по корисничком имену, претрага по биографији, *autocomplete* и “did you mean” треба да раде у *case insensitive* режиму.

ШТА ЈЕ INVERTED INDEX?

Inverted index је структура података која за сваку реч чува листу или скуп корисника код којих се та реч појављује у биографији. На пример, ако се реч *python* појављује у биографијама корисника 5, 17 и 42, онда *inverted index* за реч *python* садржи те кориснике. На овај начин се претрага убрзава, јер није потребно сваки пут пролазити кроз све биографије.

У КОЈИМ ЗАДАЦИМА ЈЕ ОБАВЕЗНО КОРИСТИТИ СТРУКТУРУ ПОДАТАКА TRIE?

Trie је префиксно стабло и примарно се користи за *autocomplete* корисничких имена. Користи се када корисник унесе почетак корисничког имена и очекује да добије неколико могућих завршетака. Дозвољено је користити *trie* и у другим деловима пројекта ако студент процени да је корисно.

ДА ЛИ AUTOCOMPLETE ТРЕБА ДА ВРАТИ БИЛО КОЈЕ КОРИСНИКЕ КОЈИ ПОЧИНЈУ ЗАДАТИМ ПРЕФИКСОМ?

Autocomplete треба да врати кориснике чија корисничка имена одговарају задатом префиксу, али резултати не треба да буду произвољно поређани. Потребно је да се прво прикажу утицајнији корисници, односно они са већом *PageRank* вредношћу.

ШТА ТАЧНО ПРЕДСТАВЉА PERSONALIZED PAGERANK (PPR)?

Personalized PageRank (PPR) је варијанта *PageRank* алгоритма која рангира кориснике из перспективе једног задатог корисника. Код обичног *PageRank*-а значај се рачуна глобално за целу мрежу. Код *PPR*-а постоји почетни корисник и рангирање треба да покаже који су корисници релевантнији баш за њега.

Интуитивно, *PPR* се може посматрати као насумична шетња кроз граф у којој постоји вероватноћа да се шетња врати назад на почетног корисника и поново крене од његовог чвора. Због тога корисници који су ближи почетном кориснику или су важни у његовом делу мреже добијају већи скор.

ДА ЛИ PPR ЗАМЕЊУЈЕ ОБИЧАН PAGERANK?

Не. Обичан *PageRank* је потребан за глобално рангирање утицаја корисника. *PPR* се користи у задатку са хибридним препорукама, јер препоруке треба да буду персонализоване за конкретног корисника.

ШТА ЗНАЧИ ХИБРИДНА ПРЕПОРУКА?

Хибридна препорука значи да се комбинују два извора информација. У овом пројекту комбинују се структура графа, преко *Personalized PageRank*-а, и сличност садржаја биографија. Ако је неки корисник близак или важан у графу праћења, то повећава *PPR* део скорa. Ако два корисника имају сличне биографије, то повећава *content_similarity* део скорa.

ШТА ПРЕДСТАВЉА ФОРМУЛА $\alpha \times PPR + (1 - \alpha) \times CONTENT_SIMILARITY$?

Ова формула представља комбиновани скор за препоруку. *PPR* део долази из графа праћења, а *content_similarity* део долази из сличности биографија. Параметар *alpha* одређује колико је важан *PPR* у односу на сличност биографија. Ако је *alpha* ближе 1, препорука се више ослања на граф. Ако је *alpha* ближе 0, препорука се више ослања на садржај биографија.

ШТА ЈЕ JACCARD СЛИЧНОСТ?

Jaccard сличност мери колико се два скупа преклапају. У овом пројекту свака биографија може да се представи као скуп речи. *Jaccard* сличност две биографије рачуна се тако што се број заједничких речи подели бројем различитих речи које се појављују у бар једној од те две биографије.

На пример, ако једна биографија има речи {python, ai, music}, а друга {python, data, ai}, заједничке речи су {python, ai}, а све различите речи су {python, ai, music, data}. *Jaccard* сличност је $2/4 = 0.5$.

ДА ЛИ ЈЕ ОБАВЕЗНО КОРИСТИТИ JACCARD СЛИЧНОСТ?

Не. Дозвољено је користити *Jaccard* сличност, једноставну *Cosine* сличност или неку другу меру сличности текста по избору студента. Важно је да студент разуме шта је имплементирао и да може да објасни како се добија *content_similarity* вредност.

КАКО СЕ МОЖЕ ИМПЛЕМЕНТИРАТИ COSINE СЛИЧНОСТ НАД БИОГРАФИЈАМА?

Једноставна варијанта је да се свака биографија представи као вектор речи. Вредност у вектору може бити број појављивања речи или само 0/1 вредност која означава да ли се реч појављује у биографији. Затим се сличност добија као косинус угла између та два вектора. Није неопходно користити напредне *NLP* библиотеке.

ДА ЛИ КОРИСНИК КОЈИ СЕ ПРЕПОРУЧУЈЕ СМЕ ВЕЋ БИТИ ПРАЋЕН?

Не. У препорукама за задатог корисника не треба приказивати кориснике које тај корисник већ прати. Такође, не треба препоручивати самог тог корисника. Поред тога, не треба препоручивати кориснике које је задати корисник блокирао, као ни кориснике који су блокирали њега.

ШТА СЕ ОЧЕКУЈЕ У ЗАДАТКУ 8 - BFS И НИВОИ КОНЕКЦИЈЕ?

Очекује се да се од задатог корисника крене кроз граф праћења и да се корисници прикажу по удаљености. Корисници на нивоу 1 су директне конекције, односно корисници до којих се стиже једном follow везом. Корисници на нивоу 2 достижни су преко једног посредника. Корисници на нивоу 3 достижни су преко два посредника, итд.

ДА ЛИ КОРИСНИК МОЖЕ ДА ЗАДА ДО КОГ НИВОА СЕ РАДИ BFS?

Да. Корисник може да зада максимални ниво претраге. На пример, ако зада ниво 3, програм треба да прикаже прве, друге и треће конекције. Потребно је водити рачуна да се исти корисник не обрађује више пута.

ДА ЛИ ОПЦИЈА 'DID YOU MEAN' ЗАХТЕВА ДА ПРВИХ НЕКОЛИКО КАРАКТЕРА КОРИСНИЧКОГ ИМЕНА БУДЕ ИСТО?

Не, не морају. Потребно је понудити неколико сличних исправних корисничких имена. Дозвољено је коришћење библиотеке за ову функционалност, или самостална имплементација алгоритма.

ДА ЛИ ЈЕ ДОЗВОЉЕНО КОРИСТИТИ ГОТОВЕ СТРУКТУРЕ ПОДАТАКА ИЗ PYTHON-A?

Да, дозвољено је користити стандардне структуре података као што су *dict*, *set*, *list*, *deque* и *heap*. Међутим, тамо где се експлицитно тражи имплементација одређене структуре или алгоритма, као што су *trie*, *PageRank*, *PPR*, *BFS*, потребно је да студент покаже сопствену имплементацију и разумевање.

ДА ЛИ ПОСТОЈИ ВРЕМЕНСКО ОГРАНИЧЕЊЕ КОД УЧИТАВАЊА ВЕЋЕГ СКУПА ПОДАТАКА?

За *medium* скуп очекује се интерактиван рад. За *full* скуп потребно је документовати време учитавања и време извршавања најскупљих операција.

ШТА ТРЕБА ДА САДРЖИ README.MD?

README.md треба да садржи кратко објашњење пројекта, начин покретања програма, опис улазних фајлова, формат података и списак имплементираних функционалности. Такође је пожељно навести пример корисника за претрагу, пример префикса за *autocomplete*, пример корисника за *BFS* и пример корисника за препоруке.

ДА ЛИ ЈЕ ПОТРЕБНО НАПРАВИТИ ГРАФИЧКИ ИНТЕРФЕЈС?

Не. Довољан је текстуални мени у конзоли. Графички интерфејс није потребан.

ДА ЛИ ЈЕ ПОТРЕБНО ЧУВАТИ ИЗМЕНЕ НАЗАД У ФАЈЛОВЕ?

Није неопходно, осим ако студент жели да имплементира и ту функционалност. Довољно је да се измене, као што су додавање нове везе праћења или ажурирање *PageRank*-а, коректно одржавају током једног покретања програма.

ДА ЛИ СЕ РЕЗУЛТАТИ ПРЕТРАГЕ И ПРЕПОРУКА МОРАЈУ ПРИКАЗАТИ У ПОТПУНОСТИ?

Не. Довољно је приказати *top* резултате, на пример првих 5, 10 или број који корисник унесе. За избор и приказ *top* резултата може се користити *heap*.

ДА ЛИ ЈЕ ПОТРЕБНО ОБЈАСНИТИ ИМПЛЕМЕНТИРАНЕ АЛГОРИТМЕ НА ОДБРАНИ?

Да. Студент треба да уме да објасни како је представио граф, како ради *PageRank*, како ради *PPR*, како је направљен *inverted index*, како се користи *trie*, како ради *BFS* и како се рачуна сличност биографија.